

مسئلہ ۱

: ۱ ب

$$P_\theta(x) = \int_z P_\theta(z) P_\theta(x|z)$$

ب) میان این مردم میں ان افراد کو جوں کو بدلیں ایجاد کرے جائے

$$P_\theta(x) = \int_z P_\theta(x,z) dz = \int_z P_\theta(z) P_\theta(x|z) dz = E_{z \sim P_\theta(z)} [P_\theta(x|z)] (z)$$

monte carlo میں جوں میں کوئی ایجاد کرنے کے لئے ایجاد کرنا چاہیے اسے استفادہ کیجیے

$$P_\theta(x) \approx \frac{1}{n} \sum_{i=1}^n P_\theta(x|z_i), \quad z_i \sim P_\theta(z)$$

: 2 ب

$$P_\theta(x) = \int_z P_\theta(z) P_\theta(x|z) = \int_z P_\theta(x,z) dz = \int_z q(z) \frac{P_\theta(x|z)}{q(z)} dz$$

خوب طور پر جسم کو توزیع کھداریم از شکل میں میں کوئی تغیرات نہیں کرے جائے sample

$$\rightarrow P_\theta(x) = \frac{1}{n} \sum_{i=1}^n \frac{P_\theta(x, z_i)}{q(z_i)} \quad z_i \sim q(z)$$

ب) دیکھا اسکا تصور دی (z) کو میدونے والا P_\theta(x|z) باشد

ج) اک (z|x) کو توزیع کھداریم اسے z ، latent variable کہا جائے وہی توزیع کھداری وہی توزیع کھداری کو کہا جائے وہی کاٹھش واریاپن اسے

: 3 ب

الف) مشتق گھری از یہ وحی دیوار سادھے از مشتق گھری از یہ کھاکھل فرب اسست / زنجابی کو الگوریتم جعلی جمعیت میانی کیتی بگردیں (مشتق گھری) جمعیت، ایسی ویسی کو ساخت را بسون / مشتق گھری کو بعد مالک دار تابع دلاریم کیک تابع معوی اسست ایسی معوی دو مداری کے $\log P_\theta(x)$ کو maximize کر کر maxmize کر

۷) مساحت قاعده P بدلیل انحراف کمی روی سطح مستقیم (x) ممکن است روزگاری اینجا مساحت قاعده P باشد.

$$\log P_\theta(x) = \log E_{z \sim q(z)} \left[\frac{P_\theta(x, z)}{q(z)} \right]$$

$\log(E[Y]) \geq E[\log(Y)]$ اسساً على ك Jensen's inequality.

$$\log P_\theta(x) \geq E_{z \sim q(z)} \left[\log \frac{P_\theta(x, z)}{q(z)} \right]$$

$$= E_{Z \sim q(z)} [\log P_\theta(x, z)] - E_{Z \sim q(z)} [\log q(z)]$$

$$L(x; \theta, q) = E_{q(z)}[\log p_\theta(x, z)] - E_{q(z)}[\log q(z)]$$

$$L(x; \theta, q) = E_{Z \sim q(z)} \left[\log \left(\frac{p_\theta(x, z)}{q(z)} \right) \right]$$

$$= E_{Z \sim q_\phi(z)} \left[\log \left(\frac{p_\theta(z|x)}{q_\phi(z)} \right) \right]$$

$$= E_{q(z)} \left[\log P_\theta(\bar{x} | x) \right] - \log q(z) + \log P_\theta(x)$$

$$L(x; \theta, q) = \log P_\theta(x) \in D_{KL}(q(z) || P_\theta(z|x))$$

$$\log_p(\tilde{z}) - L(x; \theta, q) = D_{KL}(q(z) || P_\theta(z|x))$$

نظام $\log \rho_\alpha$ في $E180$ جدول 6.1

٤ ج

(الف)

أوجيب فرض مجمع شد (د)

$$\log P_\theta(x) = L(\theta; x; \theta, \lambda) + \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z|x)$$

ذای كثيئر دنیم توم کل سعورت غير متسقین، می توانیم max. like / ELBO عبارت $\log P_\theta(x)$ بباره های توزیع قویی (λ معنی) (جستجو نهاد) -
- میتوانیم وقتی ELBO را مس بدل جستجو کنیم، چون مجموع $\partial_{\theta z}$ بذای است باعث گشتن
واحای کل معنی $\partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z|x)$ می سویم

$$\nabla_x \log P_\theta(x) = \nabla_x L(\theta, \lambda; x) + \nabla_x \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z|x)$$

$$\Theta = \nabla_x L(\theta, \lambda; x) + \nabla_x \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z|x)$$

$$\nabla_x L(\theta, \lambda; x) = -\nabla_x \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z|x)$$

(.)

$$\nabla_\theta L(x; \theta, \lambda) = E_{z \sim q_\lambda(z|x)} [\log P_\theta(x|z)] - \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z)$$

$$\nabla_\theta L(x; \theta, \lambda) = E_{z \sim q_\lambda(z|x)} [\nabla_\theta \log P_\theta(x|z)] - \nabla_\theta \partial_{\theta z} (q_\lambda(z|x)) / P_\theta(z)$$

واسطه دست بیشی تو نیم کارابانه
دست بیشی تو نیم کارابانه

و فرم دنگی که از خود داشته:

$$\nabla_\theta L(x; \theta, \lambda) = \nabla_\theta E_{z \sim q_\lambda(z|x)} [\log P_\theta(x|z)] - \nabla_\theta E_{z \sim q_\lambda(z|x)} [\log q_\lambda(z)]$$

$$= E_{z \sim q_\lambda(z|x)} [\nabla_\theta \log P_\theta(x|z)]$$

$$= \frac{1}{n} \sum_{i=1}^n \nabla_\theta \log P_\theta(x, z_i)$$

(6)

$$\nabla_{\lambda} L(x; \theta, \lambda) = \nabla_{\lambda} E_{z \sim q_{\lambda}(z|x)} [\log p_{\theta}(x|z) - \log q_{\lambda}(z|x)]$$

حالی امی این است که توزیعی که از آن نویگری و چیزی (λ) وابسته است که می خواهیم حسست را آن ها که در آن محترم. این وابستگی مابعه از آن می شود که علیکه خواهد بود روابط این این فضایی متشابه باشد. این مشتمل را بعثت می شود تا نمونه که در آن طریق معرفت مارکوی ساده و سطحی در طبقه واریانس بسیار بالا باشد.

: Reparameterization Trick

حال این است که نویگری و چیزی (λ) را توزیعی sample که می خواهیم داشت

$$z = \mu + \sigma \epsilon \quad \epsilon \sim N(0, I)$$

$$\begin{aligned} \rightarrow L(x, z; \theta) &= E_{\epsilon \sim N(0, I)} [\log p_{\theta}(x, z)] - E_{\epsilon \sim N(0, I)} [\log q_{\lambda}(z)] \\ &= E_{\epsilon \sim N(0, I)} [\nabla_{\lambda} [\log p_{\theta}(x, z) - \log q_{\lambda}(z)]] \\ &= \frac{1}{n} \sum_{i=1}^n \nabla_{\lambda} [\log p_{\theta}(x_i, z) - \log q_{\lambda}(z)] \end{aligned}$$

: 5/6

$$\log p_{\theta}(x) \geq L(x; \theta, \lambda)$$

$$\theta^* = \arg \max_{\theta} \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x_i)$$

اگر فرض کردیم است

$$\log p_{\theta}(x_i) \geq \arg \max_{\lambda} L(x_i; \theta, \lambda)$$

$$\Rightarrow \sum_i \log p_{\theta}(x_i) \geq \sum_i \arg \max_{\lambda} L(x_i; \theta, \lambda)$$

$$\Rightarrow \frac{1}{N} \sum_i \log p_{\theta}(x_i) \geq \arg \max_{\lambda_1, \dots, \lambda_N} \frac{1}{N} \sum_i L(x_i; \theta, \lambda_i)$$

(-), 61b'

Initialize θ , θ repeat

sample randomly mini-batch $(x^{(1)}, \dots, x^{(m)}) \sim \mathcal{D}^I$

sample noise m times $\varrho^{(0)} n \varrho(E)$

compute latent variable $Z^{(i)} = \mu + \epsilon_i^{(i)}$

compute gradient of the mini-batch estimator

$$g = \nabla_{\theta, \Theta} \sum_{i=1}^m L_{ELBO}(\theta, \Theta, x^{(i)}) \quad \{ \text{III} \}$$

update parameters (with SGD or Adam)

$$\begin{bmatrix} \phi \\ \theta \end{bmatrix} \leftarrow \begin{bmatrix} \phi \\ \theta \end{bmatrix} + \alpha g$$

Until convergence of ϕ, θ

I آنالایزر/ترھای θ (decoder)، (ϕ) encoder و آنالایزر را با توزیع ایجاد کنید و آنرا با θ initilize، random ϕ و θ را با $\sim \text{Normal}(\mu, \sigma^2)$ initialize، θ را با $\text{Normal}(\mu, \sigma^2)$ و ϕ را با $\text{Normal}(\mu, \sigma^2)$ initialize.

پیشگوئی از ابتلای سلیمانی

لایه latent یا لایه مخفی و لایه decoder یا لایه تولیدکننده

فراينه سامپل II می گيرم و آن را $Z = \mu + \epsilon^{(t)}$ در دستور predict در R نوشتم و در نتیجه $\epsilon^{(t)}$ را در R در دستور predict نوشتم و آن را $\hat{\epsilon}^{(t)}$ نمایم. در نتیجه $\hat{\epsilon}^{(t)}$ را در R در دستور predict نوشتم و آن را $\hat{\epsilon}^{(t)}$ نمایم.

نیز به objective function

$$\arg \max_{\theta} \arg \max_{\lambda_1, \dots, \lambda_n} \sum_i L(x_i; \theta, \lambda_i)$$

* کوادیان نیز به این نام مجهود کوادیان هایی هستند که در ELBO نیز دارند و بازگشایی کردن آنها ممکن است این معنی داشته باشند.

* کوادیان objective کوادیان هایی هستند که در ELBO نیز دارند و بازگشایی کردن آنها ممکن است این معنی داشته باشند.

آخرین خواص نیز نیست که این کوادیان در ELBO مورد بررسی قرار گیرد (۲) که در متن مذکور شد.

(۲) فرض کنید مدارهای ϕ را به صورت encoder فرموده و تابع $q_\phi(z|x)$ را می‌خواهیم

$$\mu_\phi, \sigma_\phi^2 = NN(\mathbf{x}; \phi)$$

که بازگشتی $q_\phi(z|x)$ می‌باشد که مقدار z را می‌گیرد.

$$L(x; \theta, \phi) = E_{z \sim q_\phi(z|x)} [\log p_\theta(x, z) - \log q_\phi(z|x_i)]$$

6 پیش

(۱)

$$L(x; \theta, \phi) = E_{z \sim q_\phi(z|x)} \left[\frac{\log p_\theta(x|z)}{q_\phi(z|x_i)} \right]$$

$$L_\phi(x; \theta, \phi) = E_{z \sim q_\phi(z|x)} \left[\frac{\log p_\theta(x|z) P_\theta(z)}{q_\phi(z|x_i)} \right]$$

$$L(x; \theta, \phi) = E_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)] - E_{z \sim q_\phi(z|x)} \left[\frac{q_\phi(z|x_i)}{p_\theta(z)} \right]$$

$$L(x; \theta, \phi) = E_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)] - KL(q_\phi(z|x) || p_\theta(z))$$

سوال 2

(الف)

مقدار احتمال $P(x)$ لـ log likelihood

$$E_{z \sim q(z_1, z_2 | x)} [\log P(x)] = E_{z \sim q(z_1, z_2 | x)} \left[\log \frac{P(x, z_1, z_2)}{P(z_1, z_2 | x)} \right] = E_{z \sim q(z_1, z_2 | x)} \left[\log \frac{P(x | z_1) P(z_1 | z_2) P(z_2)}{P(z_1, z_2 | x)} \right]$$

$$= E_{z \sim q(z_1, z_2 | x)} \left[\frac{\log P(x | z_1) P(z_1 | z_2) P(z_2)}{P(z_1 | x) P(z_2 | x)} \right] = E_{z \sim q(z_1, z_2 | x)} \left[\frac{\log P(x | z_1) P(z_1 | z_2) P(z_2)}{P(z_1 | x) P(z_2 | x)} \times \frac{q(z_1, z_2 | x)}{q(z_1, z_2 | x)} \right]$$

$$E_{z \sim q(z_1, z_2 | x)} \left[\log \left(P(x | z_1) \times \left(\frac{q(z_1 | x) q(z_2 | z_1)}{P(z_1 | z_2) P(z_2)} \right)^{-1} \times \frac{q(z_1 | x) q(z_2 | z_1)}{P(z_1 | x) P(z_2 | x)} \right) \right]$$

$$= E_{z \sim q(z_1, z_2 | x)} [\log (P(x | z_1))] - E_{z \sim q(z_1, z_2 | x)} \left[\log \frac{q(z_1 | x) q(z_2 | z_1)}{P(z_1 | z_2) P(z_2)} \right] + KL \left[q(z_1, z_2 | x) || P(z_1, z_2 | x) \right]$$

$$\rightarrow -E_{z \sim q(z_1 | x) q(z_2 | z_1)} \left[\log \frac{q(z_1 | x) q(z_2 | z_1)}{P(z_1 | z_2) P(z_2)} \right]$$

$$= \left[E_{z \sim q(z_1 | x) q(z_2 | z_1)} \left[\log \frac{q(z_2 | z_1)}{P(z_2)} \right] + E_{z \sim q(z_1 | x) q(z_2 | z_1)} \left[\log \frac{q(z_1 | x)}{P(z_1 | z_2)} \right] \right]$$

$$= - \left[E_{z \sim q(z_1 | x)} \left[E_{z \sim q(z_2 | z_1)} \left[\log \frac{q(z_2 | z_1)}{P(z_2)} \right] \right] + E_{z \sim q(z_1 | x) q(z_2 | z_1)} \left[\log \frac{q(z_1 | x)}{P(z_1 | z_2)} \right] \right]$$

$$= -E_{z \sim q(z_1 | x)} \left[KL(q(z_2 | z_1) || P(z_2)) \right] - E_{z \sim q(z_1 | x) q(z_2 | z_1)} \left[\log \frac{q(z_1 | x)}{P(z_1 | z_2)} \right]$$

$$\rightarrow -E_{q(z_1 | x)} [\log (z_1 | x) - E_{q(z_2 | z_1)} [\log P(z_1 | z_2)]]$$

$$\rightarrow \log \tilde{P}(z_1) = E_{q(z_1 | x)} [\log P(z_1 | z_2)]$$

$$\cong -E_{q(z_1 | x)} \left[\log \frac{q(z_1 | x)}{P(z_1)} \right] = -KL(q(z_1 | x) || \tilde{P}(z_1))$$

$$\rightarrow E_{z \sim q(z, z_1 | x)} [\log P(x)] = E_{z \sim q(z_1, z_2 | x)} [\log P(x | z_1)] - E_{z \sim q(z_1 | x)} [KL(q(z_2 | z_1) || P(z_2))]$$

$$- E_{z \sim q(z_2 | z_1)} [KL(q(z_1 | x) || P(z_1 | z_2))] + \underbrace{KL[q(z_1, z_2 | x) || P(z_1, z_2 | x)]}_{\text{intractible}}$$

(ب) قسم اول:

برای تخمین \hat{x} که در میان x و \hat{x} میانگین μ باشد، از $\text{KL}(\hat{x} \parallel x)$ استفاده می‌کنند. این معادله را می‌توان به صورت زیر نوشت:

$$\text{KL}(\hat{x} \parallel x) = \sum_{i=1}^n p_i \log \frac{p_i}{q_i}$$

تومی:

میزان تسبیحت (Mean) سطح الاتکیت (latent variable) از (استنادی معنی شد) به وزیر (Minister of Information) میگذرد که ساده $f_{\theta}(z)$ را از ارتباط قدرتمند با محیط که در آن زیر مدل به سوچ این مدل بعنوان مکانیزمه (regularizer) معرفی میکند. با توجه کردن این ترم مدل به سوچ و محدود کردن رابطه کوئی استنادی محدود نمایندگی دارد این مدل ابتدا نمونه هایی را از \mathcal{Z} برداشت کرده و از آنها برای تولید مدارهای x استفاده میکند.

تَوْمَسُونْ:

این علت در این شاخص توزیع $p(z|x)$ (عنی توزیع z که می‌گذرد و داده x بوده است) می‌باشد

(posterior collapse) \rightarrow $f_U(1)$

: 3 جول

ابتداء ساعِ عبارت زیری روم:

$$\inf_{D \in D} \left\{ \int [(sth) \varphi_\delta(x) + (sth) \varphi_g(x)] dx \right\}$$

در واقع این میانجیگان جمع گردیده از راهدهای واقعی و غنیمت است

۱) sample / روزنیم واقعی یعنی μ میانگین کل آن ۵۰ بچسبی واقعی دلیل این داده‌ها است.

نیز رایج loss جایز است.

② دایردادهایی خیلی بعورت هستند اگر sample از توزیع دادهای حقیق شده باشند و آنها میتوانند این را نشان کنند.

| (-1, 0.95) | \leftarrow min loss = 0.5

جنابیان(0) R_I رابطه روت زیر لاز نویسی می کند

$$R_I(D) = \int_{-\infty}^{\infty} 0.5 p_g(x) \cdot I(D(x)) + 0.5 p_g(x) \cdot I(-D(x)) dx$$

$$\rightarrow \inf_{D \in D} \left\{ [0.5 \cdot 1(D(x)) \cdot p_d(x) + 0.5 \cdot 1(-D(x)) \cdot p_g(x)] \right\} dx$$

وای سادجی از نو ددنس $(n=1)$ استقاده‌ی کمی پس درین

$$L(d, \alpha) = \rho_d(\alpha) I(d) + \rho_{\bar{d}} I(-d)$$

$R_I(D) = \int \frac{1}{2} [inf \ell(d, u)] dx$ جزو انتگرال دسکی کردن نه دین سیدهش \rightarrow داخل انتگرال

می تو نہیں دیکھ سو کے شواطیء میں اور رفاقت کے تحریف کیجیئے

$$l(d, x) = p_d(x) e^{-d} + q_g(x) e^d$$

دلیل برای این است که ممکن است در اینجا مقداری از این اثربخشی را مشاهده نکنیم.

$$\frac{\partial L}{\partial t} = -p_g(x) e^{-d} + p_g(x) e^d = 0$$

$$\Rightarrow \varrho_g(x) e^d = \varrho_d(x) e^{-d} \Rightarrow e^{2d} = \frac{\varrho_d(x)}{\varrho_g(x)}$$

$$\Rightarrow d^* = \frac{1}{2} \log \left(\frac{P_d(x)}{P_g(x)} \right)$$

۲) تجزیه برای جان اطلاعات،

- ۱) این یک دیده دشمنی برای مقدار اطلاعات / داده و داده های دیگر فهرست خواهد بود - این latent variable منع شدن
یا در عکس، اطلاعات از نایابی اطلاعاتی که از این طریق فراخواسته استفاده می شوند
- ۲) این یک دیده خوب است که دیگر این یک دیده خوب است که دیگری و دیگری باشی ممکن است در این پیش از
معکوس در راه داده های سوزن را در عکس آنها را در چشم خود
- ۳) مخفف از ساختار های Hierarchical، دیگری دیگری مخصوصاً مخفف انتخاب است - این دیده ای این معنی است
که ساختار های هیرارشی شناخته شده و بقیه ایها امروزه با غیر طردی شده اند

۳) جو دیگری در این جلوگیری از این دیده

- ۱) KL Annealing:
در این روش خودن جلوی ۷۰ در تابع هزینه ELBO را فصل خواهد آورد تا آن را از این طریق طاده می شود.
همچنان با این صورت با جیسیار کم داشته باشید اما آنها را با این طریق برای اینجا خود دیگری
و افزایشی می باید
- ۲) در این اولیه training مامکرون ورن که این مدل پیشتر برای استخراج اطلاعات مخفی برای این احتمال
را فضای محدود کنند که این مخفف طبقه Latent variable استفاده کنند و اطلاعات مخفی برای این احتمال
صل از اینکه فشار و کلایزی نزدیکی کردن ترتیب posterior : $P(z|x)$ خواهد شد، فرضیه می باشد
که می توان این محدودیت را برای این مدل برداشت.

۴) استفاده از decoder = ضعیف تر:

- ۱) ضعیفیت یافرست بقیه decoder ها $P(x|z_1)$ که مخفف داده شود می باشد از این طریق خود
همچنان با پیشگیری از استفاده از شفود کی امداد با این ترتیب اکنون می شود
- ۲) این استفاده از decoder های برای بازسازی دستورات داده ها، سازند اطلاعات پس از این طریق
Latent variable استفاده کرده اند که این دستورات داده ها را بازسازی کرده اند و این امر از عدم مغایری می باشد
نتیجه های توافق برای Latent variable

$$R(D) = \frac{1}{2} \int [(\rho_d + \rho_g)(\log(\rho_d + \rho_g) - \log_{\rho_g}) - \rho_d(\log \rho_g - \log \rho_g)] dx$$

$$R(D) = \frac{1}{2} \int [\rho_d(\log(\rho_d + \rho_g) - \log \rho_d) + \rho_g(\log(\rho_d + \rho_g) - \log \rho_g)] dx$$

$$R(D) = \frac{1}{2} \int [\rho_d \log \left(\frac{\rho_d + \rho_g}{\rho_d} \right) + \rho_g \log \left(\frac{\rho_d + \rho_g}{\rho_g} \right)] dx$$

$$m(x) = \frac{\rho_d(x) + \rho_g(x)}{2}$$

$$\rho_d + \rho_g = 2m \quad R(D) = \frac{1}{2} \int [\rho_d \log \left(\frac{2m}{\rho_d} \right) + \rho_g \log \left(\frac{2m}{\rho_g} \right)] dx$$

$$= \frac{1}{2} \int [\rho_d (\log 2 + \log \frac{m}{\rho_d}) + \rho_g (\log 2 + \log \frac{m}{\rho_g})] dx$$

$$R(D) = \underbrace{\frac{1}{2} \int (\rho_d + \rho_g) \log 2 dx}_I + \underbrace{\frac{1}{2} \int \left(\rho_d \log \frac{m}{\rho_d} + \rho_g \log \frac{m}{\rho_g} \right) dx}_{II}$$

$$I: \int (\rho_d + \rho_g) dx = \int \rho_d dx + \int \rho_g dx = 1 + 1 \rightarrow \frac{1}{2} \times 2 \times \log 2 = \log 2$$

$$II: I_{JS} = \frac{1}{2} D_{KL}(\rho_d || m) + \frac{1}{2} D_{KL}(\rho_g || m) = \frac{1}{2} \int \rho_d \log \frac{\rho_d}{m} dx + \frac{1}{2} \int \rho_g \log \frac{\rho_g}{m} dx$$

$$\rightarrow \frac{1}{2} \left(\rho_d \log \frac{m}{\rho_d} + \rho_g \log \frac{m}{\rho_g} \right) dx = -I_{JS}$$

$$R(D) = \log 2 - I_{JS}(\rho_d, \rho_g)$$

كذلك minimize $\int g(d, u) = u(1-d)^2 + (1+d)^2$ معايير خواص

$$\frac{\partial g}{\partial d} = -2u(1-d) + 2(1+d) = 0 \Rightarrow d^* = \frac{u-1}{u+1}$$

$$f(u) = u\left(1 - \frac{u-1}{u+1}\right)^2 + \left(1 + \frac{u-1}{u+1}\right)^2$$

$$f(u) = \frac{4u}{u+1} \rightarrow f(u) = -\frac{4u}{u+1}$$

$$D^*(x) = \frac{\frac{p_d(x)}{p_g(x)} - 1}{\frac{p_d(x)}{p_g(x)} + 1} = \frac{p_d(x) - p_g(x)}{p_d(x) + p_g(x)} \rightarrow \text{optimal discriminator}$$

$$R(D) = \frac{1}{2} \int p_g(x) \left(\frac{4u}{u+1}\right) dx = \frac{1}{2} \int \frac{p_d(x)p_g(x)}{p_d(x) + p_g(x)} dx$$

$$\rightarrow R(D) = \frac{1}{2} I_g(p_d, p_g), g(t) = \frac{4t}{t+1}$$

$$g(d, u) = u \log(1 - e^{-d}) + \log(1 + e^d)$$

$$\frac{\partial g}{\partial d} = u \left(\frac{-e^{-d}}{1 + e^{-d}} \right) + \frac{e^d}{1 + e^d} = 0 \rightarrow u = e^d \Rightarrow d^* = \log u$$

$$f(u) = u \log(1 + e^{-\log u}) + \log(1 + e^{\log u}) = (u+1) \log(u+1) - u \log u$$

$$D^*(x) = \log \left(\frac{p_d(x)}{p_g(x)} \right)$$

$$R(D) = \frac{1}{2} \int p_g(x) [(u+1) \log(u+1) - u \log u] dx$$

$$R(D) = \frac{1}{2} \int p_g(x) \left[\left(\frac{p_d}{p_g} + 1 \right) \log \left(\frac{p_d}{p_g} + 1 \right) - \frac{p_d}{p_g} \log \left(\frac{p_d}{p_g} \right) \right] dx$$

$$= \frac{1}{2} \int \left[(p_d + p_g) \log \left(\frac{p_d + p_g}{p_g} \right) - p_d \log \left(\frac{p_d}{p_g} \right) \right] dx$$

جذب

رجلي اينما $f(u)$ بحسب مقداره تأثير $R_I(D)$ على كثافته

$$f(u) = \min \{u \cdot I(d) + 1 \cdot (-d)\}$$

$$\rightarrow u = \frac{R_d(u)}{R_g(u)}, d = D(u), R_I(D) = \frac{1}{2} \int \rho_g(x) [-f(x)] dx$$

(الف)

$$\text{يمكن}\min_{d} \int g(d, u) = u I(d \leq 0) + I(-d < 0)$$

$$g(d, u) = u \cdot 0 + 1 = 1 \quad d \geq 0$$

$$g(d, u) = u \cdot 1 + 0 = u \quad d < 0$$

$$g(d, u) = u \cdot 1 + 1 = u + 1 \quad d = 0$$

نحو ادناه

$$\begin{cases} \text{غير ملحوظ} \\ \text{محض} \end{cases} \rightarrow f(x) = \min(u, 1) \rightarrow f(u) = \min(u, 1)$$

: $D^*(x)$ يمثل كثافة

لكل $x > 1$ نعم (يعني $\rho_g(x) > \rho_d(x)$) و لباقي x (يعني $\rho_d(x) > \rho_g(x)$) يتحقق المعاين (مدل) اختبار شود
 ولكل $x < 1$ نعم (يعني $\rho_d(x) > \rho_g(x)$) و لباقي x (يعني $\rho_g(x) > \rho_d(x)$) يتحقق المعاين (مدل) اختبار شود

نحو ادناه يتحقق المعاين (مدل) في كل x ملحوظ

$$\rightarrow R_g(D) = \frac{1}{2} \int \rho_g(x) \min\left(\frac{\rho_d(x)}{\rho_g(x)}, 1\right) dx = \frac{1}{2} \int \min(\rho_d(x), \rho_g(x)) dx$$

$$\int \min(p, q) dx = 1 - \frac{1}{2} \int |p - q| dx \quad *$$

$$I_{TN}(P, Q) = \frac{1}{2} \int |P - Q| dx \quad *$$

$$\rightarrow R(D) = \frac{1}{2} (1 - I_{TV}(P_d, P_g))$$

از اینجا که مسأله داشتیم $\rho_d(x)e^{-d} + \rho_g(x)e^d$ بود که مینیمم دارد.

$$L(d^*, x) = \rho_d(x)e^{-d^*} + \rho_g(x)e^{d^*}$$

$$\left\{ \begin{array}{l} e^{d^*} = \sqrt{\frac{\rho_g(x)}{\rho_d(x)}} \\ e^{-d^*} = \sqrt{\frac{\rho_d(x)}{\rho_g(x)}} \end{array} \right.$$

$$L(d^*, x) = \rho_d(x)\sqrt{\frac{\rho_g(x)}{\rho_d(x)}} + \rho_g(x)\sqrt{\frac{\rho_d(x)}{\rho_g(x)}}$$

$$L(d^*, x) = 2\sqrt{\rho_d(x)\rho_g(x)}$$

$$\rightarrow \inf R_I(D) = \int \frac{1}{2} (2\sqrt{\rho_d(x)\rho_g(x)}) dx = \int \sqrt{\rho_d(x)\rho_g(x)} dx$$

در صورت تغییر چندین سه که دشمن را هم توجه نماید باشد

$$-\frac{1}{2} \int f\left(\frac{\rho_d(x)}{\rho_g(x)}\right) \rho_g(x) dx$$

اول باید خرم $\sqrt{\rho_d(x)\rho_g(x)}$ را حذف کنیم تا شبیه خرم باشد

$$\sqrt{\rho_d(x)\rho_g(x)} = \sqrt{\frac{\rho_d(x)}{\rho_g(x)}} \rho_g^2(x) = \sqrt{\frac{\rho_d(x)}{\rho_g(x)}} \rho_g(x)$$

$$\rightarrow \inf R_I(D) = \int \sqrt{\frac{\rho_d(x)}{\rho_g(x)}} \rho_g(x) dx$$

$$\text{طبعاً } \alpha = \frac{\rho_d(x)}{\rho_g(x)}$$

$$-\frac{1}{2} f(\alpha) \rho_g(x) = \sqrt{\alpha} \rho_g(x)$$

$$\rightarrow f(\alpha) = -2\sqrt{\alpha}$$

جیکو کردن و ترجیحات

نمایل بودم،

$$f'(\alpha) = -\frac{1}{\sqrt{\alpha}}$$

از اینجا که α نسبت 2/1 بود است حدیثه صحبت نمی شوند $(\alpha > 0)$ پس $f(\alpha)$ در این بازه رفعی است، رفعی بدون آنست

$$f''(\alpha) = \frac{1}{2\sqrt{\alpha^3}}$$

از اینجا که $f''(\alpha) < 0$ می شوند $f(\alpha)$ در این بازه رفعی است

سی || خصائص (الف)
انتظاری داخلي / Expectation

$$\|s_\theta(x) - \nabla_x \log q(x)\|^2 = \|s_\theta(x)\|^2 - 2s_\theta(x) \cdot \nabla_x \log q(x) + \|\nabla_x \log q(x)\|^2$$

$$I(\theta) = E_{q(x)} \left[\frac{1}{2} \|s_\theta(x)\|^2 \right] - E_{q(x)} [s_\theta(x) \cdot \nabla_x \log q(x)] + E_{q(x)} \left[\frac{1}{2} \|\nabla_x \log q(x)\|^2 \right]$$

I: این قسم در حکم ماتری در راه جی نیازی نداشت تغییراتی بین
III: این قسم تنها به توزیع پارامتر θ بستگی دارد و به پارامتر θ بستگی ندارد
ثابت C_1 در فقره چهارم
II: این قسم نیاز به تغییر در روش حکم سوال برخیم

$$E_{q(x)} [s_\theta(x) \cdot \nabla_x \log q(x)] = \int_x q(x) (s_\theta(x) \cdot \nabla_x \log q(x)) dx$$

$$\nabla_x \log q(x) = \frac{\nabla_x q(x)}{q(x)} \quad \int_x q(x) \left(s_\theta(x) \cdot \frac{\nabla_x q(x)}{q(x)} \right) dx = \int_x s_\theta(x) \cdot \nabla_x q(x) dx$$

$$\sum_i \int_x s_{\theta,i}(x) \frac{\partial q(x)}{\partial x_i} dx, \text{ که این معنی دارد که } \dim \mathcal{X} = n$$

$$\xrightarrow{\text{ایجاد}} \int_x s_{\theta,i}(x) \frac{\partial q(x)}{\partial x_i} dx = [s_{\theta,i}(x) q(x)]_{-\infty}^{+\infty} - \int_x q(x) \frac{\partial s_{\theta,i}(x)}{\partial x_i} dx$$

$$\sum_i \int_x s_{\theta,i}(x) \frac{\partial q(x)}{\partial x_i} dx = \sum_i \left(- \int_x q(x) \frac{\partial s_{\theta,i}(x)}{\partial x_i} dx \right) = - \int_x q(x) \left(\sum_i \frac{\partial s_{\theta,i}(x)}{\partial x_i} \right) dx$$

$$= - E_{q(x)} [T \nabla_x s_\theta(x)]$$

$$\rightarrow I(\theta) = E_{q(x)} \left[\frac{1}{2} \|s_\theta(x)\|^2 + T \nabla_x s_\theta(x) \right] + C_1$$

آنکه همین مفهوم علی مناسب سمت چون (حاصلی) $T(s_\theta(x))$ بسیار بزرگ نیست است که این یک ماتریس را کوچک کند
است. اگر مدعی می شود عکس یا اعداد اساس را کوچک کنند که این کار را می توانیم در مقاله خواهد بود
که مدعی تأمین می کند این ماده های خوبی دارند که نمونه در مقاله از آن مذکور شده است.

(پیش ب)

$$l_3(\theta) = E_{\tilde{x} \sim q(x), \epsilon \sim N(0, I)} \left[\frac{1}{2} \| s_\theta(x + \sigma \epsilon) + \frac{\tilde{x} - x}{\sigma^2} \|^2 \right]$$

$$\begin{aligned} \tilde{x} &= x + \sigma \epsilon \\ \epsilon &= \frac{\tilde{x} - x}{\sigma^2} \end{aligned} \rightarrow l_3(\theta) = E_{q(x, \tilde{x})} \left[\frac{1}{2} \| s_\theta(\tilde{x}) + \frac{\tilde{x} - x}{\sigma^2} \|^2 \right]$$

$$\begin{aligned} \nabla_{\tilde{x}} \log p(\tilde{x}|x) &= \frac{1}{\sigma^2} (x - \tilde{x}) \\ &= -\frac{\tilde{x} - x}{\sigma^2} \end{aligned} \rightarrow l_3(\theta) = E_{q(x, \tilde{x})} \left[\frac{1}{2} \| s_\theta(\tilde{x}) - \nabla_{\tilde{x}} \log q(\tilde{x}|x) \|^2 \right]$$

مس. score matching با این روش دو مراحل در این objective دارد

$$L_{sm}(\theta) = E_{q(\tilde{x})} \left[\frac{1}{2} \| s_\theta(\tilde{x}) - \nabla_{\tilde{x}} \log q(\tilde{x}) \|^2 \right]$$

$$\xrightarrow{\text{DSM obj}} l_3(\theta) = E_{q(x, \tilde{x})} \left[\underbrace{\frac{1}{2} \| s_\theta(\tilde{x}) \|^2}_{\text{I}} - \underbrace{s_\theta(\tilde{x}) \cdot \nabla_{\tilde{x}} \log q(\tilde{x}|x)}_{\text{II}} + \underbrace{\frac{1}{2} \| \nabla_{\tilde{x}} \log q(\tilde{x}|x) \|^2}_{\text{III}} \right]$$

- I این قسم که اصل sm نامیده شد کاریکاری دارد
 II این قسم به فروزگشی طارمهای پارامترهای محل و اجزاء دیست پس از مجموعه است
 III این قسم از ریاضی اصل سود داده شد و دارای $E_{q(\tilde{x})} [TV(\nabla_{\tilde{x}} s_\theta(\tilde{x}))]$ است

ساواح دو مراحل در این objective دارد

$$l_3(\theta) = E_{q(\tilde{x})} \left[\frac{1}{2} \| s_\theta(\tilde{x}) \|^2 + TV(\nabla_{\tilde{x}} s_\theta(\tilde{x})) \right] + C$$

$$L_{sm}(\theta) = E_{q(\tilde{x})} \left[\frac{1}{2} \| s_\theta(\tilde{x}) \|^2 + TV(\nabla_{\tilde{x}} s_\theta(\tilde{x})) \right] + C'$$

ساختاری داشت که $L_{sm}(\theta)$ و $l_3(\theta)$ داشتند و همچنان که $L_{sm}(\theta)$ داشتند $l_3(\theta)$ داشتند
 اما $L_{sm}(\theta)$ داشتند که در آن $l_3(\theta)$ داشتند و $l_3(\theta)$ داشتند که در آن $L_{sm}(\theta)$ داشتند
 همچنان که $L_{sm}(\theta)$ داشتند که در آن $l_3(\theta)$ داشتند و $l_3(\theta)$ داشتند که در آن $L_{sm}(\theta)$ داشتند

سوال ۵:

$$q_0(x_t/x_0) = N(\sqrt{\alpha_t}x_0, (1-\alpha_t)I)$$

این استقراء:

دایی آنچه پیش ران یعنی توزیع خاصیتی مستقیماً در تعویض q_0 به داده قسماً است

$$q_0(x_t/x_0) = N(x_t; \sqrt{\alpha_t}x_0, (1-\alpha_t)I)$$

این را با فرض معمولی مطابق سازیم یا این استقراء بوقور است

فرضی استقراء:

فرضی کنیم که دلیل یک مطالعه دلخواه θ (درین $t > t_0$) توزیع خاصیتی مستقیماً در تعویض x_t دارد

$$q_0(x_t/x_0) = N(x_t; \sqrt{\alpha_t}x_0, (1-\alpha_t)I)$$

پنجم استقراء:

اگرچه باید ساند بدهم که توزیع خاصیتی برای x_t مطالعه θ صلی، یعنی $1 - \alpha_t$ نیازهای فرضی سنتی بخواهد
یا فرض $q_0(x_{t+1}/x_t) = q_0(x_{t+1}/x_t, x_0)$ از توزیع $q_0(x_{t+1}/x_t, x_0)$ وی معترض x_t است که لذتگیرم

$$q_0(x_{t+1}/x_t) = \int q_0(x_{t+1}/x_t, x_0) q_0(x_t/x_0) dx_t$$

این عبارت را انتگرال رهی ماتلاب فرب دو توزیع گوسی است و سه آن بیریت توزیع گوسی خواهد بود. طبق استحصال گفته شد
این توزیع جدید را ماتلاب چشم

$$\mu_t = \sqrt{\alpha_t}x_0$$

$$\Sigma_t = (1-\alpha_t)I$$

$$x_t \sim N(\mu_t, \Sigma_t) \quad \text{در ماتلاب خوب}$$

$$x_{t+1} \sim N(Ax_t + b, \Sigma_{t+1}) \quad \text{ذو گوشی است} \quad (x_{t+1}/x_t, x_0)$$

$$A = \frac{\sqrt{1-\alpha_{t+1}}\sigma_t^2}{\sqrt{1-\alpha_t}} I$$

$$b = \sqrt{\alpha_{t+1}}x_0 - A\sqrt{\alpha_t}x_0$$

$$\Sigma_{t+1/b} = \sigma_t^2 I$$

۱/ استimation: خواص تبیین ضمی متفوہی گھصی، توزیع حاسی ای حاصل داشت - α_t بی توزیع چو سلیمانی، μ_{t-1} نجوم

در

 μ_{t-1}

$$\mu_{t-1} = E[x_{t-1}] = A\mu_t + b$$

$$\mu_{t-1} = \left(\frac{\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}}{\sqrt{1-\bar{\alpha}_t}} I \right) (\sqrt{\bar{\alpha}_t} x_0) + \left(\sqrt{\bar{\alpha}_{t-1}} x_0 - \frac{\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}}{\sqrt{1-\bar{\alpha}_t}} \sqrt{\bar{\alpha}_t} x_0 \right)$$

$$\mu_{t-1} = \sqrt{\bar{\alpha}_{t-1}} x_0$$

 Σ_{t-1}

$$\Sigma_{t-1} = \text{cov}(x_{t-1}) = A \Sigma_t A^T + \Sigma_{t-1|t}$$

$$\Sigma_{t-1} = \left(\frac{\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}}{\sqrt{1-\bar{\alpha}_t}} I \right) ((1-\bar{\alpha}_t) I) \left(\frac{\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}}{\sqrt{1-\bar{\alpha}_t}} I \right)^T + \sigma_t^2 I$$

$$\Sigma_{t-1} = \frac{1-\bar{\alpha}_{t-1}-\sigma_t^2}{1-\bar{\alpha}_t} (1-\bar{\alpha}_t) I + \sigma_t^2 I$$

$$\Sigma_{t-1} = (1-\bar{\alpha}_{t-1}-\sigma_t^2) I + \sigma_t^2 I$$

$$\Sigma_{t-1} = (1-\bar{\alpha}_{t-1}) I$$

این یعنی و که در اینجا مطابق با مجموع مساحت میدان استوار است

امروز

(ب)

اینجا ویدیو / elbo

$$L_{ELBO} = E_{q_\theta(x_0:T)} \left[\log \frac{P_\theta(x_0:T)}{q_\theta(x_0:T|x_0)} \right]$$

$$L_{ELBO} = \underbrace{E_{q_\theta}[\log P_\theta(x_0|x_1)]}_{L_0} + \sum_{t=2}^T \underbrace{E_{q_\theta}[\log \frac{P_\theta(x_{t-1}|x_t)}{q_\theta(x_{t-1}|x_t, x_0)}]}_{L_{t-1}} - \underbrace{E_{q_\theta}[D_{KL}(q_\theta(x_T|x_0) || P_\theta(x_T))]}_{L_T}$$

نماینده برآوردهای مدل (θ) واحد نیست و در یونین سانی تبدیل گفته می شود

$$\begin{aligned} & L_{\text{ELBO}} = -\mathbb{E}_{q_\theta}[\log P_\theta(x_T|x_0)] \\ & \quad + \mathbb{E}_{q_\theta}[\log q_\theta(x_{t-1}|x_t, x_0)] \\ & \quad + \mathbb{E}_{q_\theta}[\log P_\theta(x_t|x_{t-1})] \end{aligned}$$

واریانس اول توزیع گوسی مکسانی و برآوردهای L_{ELBO} است اما این دو نوع گوسی با کهواریاس معانی متفاوت
با تغییر دهنده می باشند و توزیع تخطی در پیش معرفه ممکن است متفاوت باشد (در عکس)
و ممکن است متوسط مدل دینامیکی شود

$$L_{t-1} \propto -\mathbb{E}_{q_\theta} [\| f_\theta^{(t)}(x_t) - x_t \| ^2]$$

$$f_\theta^{(t)}(x_t) = x_0 = \frac{x_t - \sqrt{1-\alpha_t} \epsilon_t^{(t)}}{\sqrt{\alpha_t}} = \frac{x_t - \sqrt{1-\alpha_t} \epsilon}{\sqrt{\alpha_t}} = \frac{\sqrt{1-\alpha_t}}{\sqrt{\alpha_t}} (\epsilon_t^{(t)} - \epsilon)$$

مارکون چشم هدف این توزیع را به توزیع مارکونی تبدیل می نماید

$$L_{\text{total}} = \min_{\theta} \sum_{t=1}^T \mathbb{E}_{q_\theta} [\| \epsilon_t (\sqrt{\alpha_t} x_0 + \sqrt{1-\alpha_t} \epsilon_t, t) - \epsilon_t \| ^2]$$

این مدل objective مارکونی توزیع را به توزیع مارکونی دینامیکی تبدیل می نماید

حواله برسن،
این دیگران با صفت در قوی گروه مارکسی ($\rightarrow \sigma$) همراهند که این نهاد را از نظر تصادفی به یک فوایند کارهای حقیقی تبدیل
کرده اند این فوایند حقیقی عامل مؤلفه DIDI ۰۰۱ است

خوبی این کار، افق ایدئوگرایی که اسیر بودن حقیقی است، و گنجینه ای به چهودن کارهای
حقیقی را در میان ۱۰۰۰ کاری درست. در عوضی می توانیم این کارها اس کامپانی بزرگتر و پیشوند که زیر دست از برخانی
حقیقی را با سلطنت جنسیار پیشتری تولید کرد و همان را بسته طبقه داد.